1. What is the primary goal of Univariate Analysis?

Univariate Analysis-இன் முக்கிய நோக்கம் என்ன?

A) To study the relationship between two variables
இரண்டு மாறிகளுக்கிடையேயான உறவை ஆய்வு செய்வது

✔️ **B) To summarize and describe the main characteristics of one variable**
ஒரு மாறியின் முக்கிய பண்புகளை சுருக்கமாக விளக்குவது

C) To predict future data points
எதிர்கால தரவை கணிக்குவது

---

2. Which visualization is best for identifying the spread of a single variable?

ஒரு மாறியின் பரவலை **(spread)** கண்டறிய சிறந்த **visualization** எது**?**

A) Scatter Plot
Scatter Plot

✔️ **B) Histogram**
Histogram

C) Line Plot
Line Plot

---

3. In Bivariate Analysis, what is the main focus?

Bivariate Analysis-இல் முக்கிய கவனம் எதில் இருக்கும்**?**

A) Analyzing one variable at a time
ஒரே மாறியை மட்டும் ஆய்வு செய்வது

✔️ **B) Exploring the relationship between two variables**
இரண்டு மாறிகளுக்கிடையேயான உறவை ஆய்வு செய்வது

C) Creating machine learning models
Machine Learning மாடல்கள் உருவாக்குவது

---

4. Which central tendency measure is influenced most by outliers?

Outliers அதிகமாக பாதிக்கும் Central Tendency measure எது?

✔️ **A) Mean**
Mean (சராசரி)

B) Median
Median (நடுத்தர மதிப்பு)

C) Mode
Mode (அதிகம் வரும் மதிப்பு)

---

5. What does a positively skewed distribution indicate?

Positively skewed distribution என்றால் என்ன?

✔️ **A) Data has a longer tail on the right side**
தரவின் வால் **(tail)** வலது பக்கம் நீளமாக இருக்கும்

B) Data has a longer tail on the left side
தரவின் வால் இடது பக்கம் நீளமாக இருக்கும்

C) Data is symmetrically distributed
தரவு சமச்சீராக இருக்கும்

---

6. Which plot is most suitable for analyzing the relationship between two continuous variables?

இரண்டு **Continuous Variables-**இன் உறவை ஆய்வு செய்ய ஏற்ற **plot** எது**?**

A) Box Plot
Box Plot

✔️ **B) Scatter Plot**
Scatter Plot

C) Pie Chart
Pie Chart

---

7. What is a characteristic feature of a normal distribution?

Normal Distribution-இன் முக்கிய தன்மை என்ன?

✔️ **A) Symmetrical bell-shaped curve**
சமச்சீரான மணி வடிவ **(bell-shaped)** வளைவு

B) Long right tail
வலது பக்கம் நீளமான வால்

C) Flat shape with no peaks
உச்சி இல்லாத flat வடிவம்

---

8. If the correlation coefficient between two variables is 0.9, what does it imply?

Correlation coefficient 0.9 என்றால் என்ன அர்த்தம்?

✔️ **A) Strong positive correlation**
மிகவும் வலுவான **Positive Correlation**

B) Weak correlation
பலவீனமான தொடர்பு

C) No correlation
எந்த தொடர்பும் இல்லை

---

9. What does a violin plot combine?

Violin Plot எதை இணைக்கிறது?

✔️ **A) Box plot and KDE (Kernel Density Estimate)**
Box Plot மற்றும் **KDE (Kernel Density Estimate)**

B) Histogram and Scatter Plot
Histogram மற்றும் Scatter Plot

C) Pie Chart and Line Plot
Pie Chart மற்றும் Line Plot

---

10. Which measure is used to find how spread out data points are?

தரவு எவ்வளவு பரவலாக உள்ளது என்பதை அளவிட எந்த **measure** பயன்படுத்தப்படுகிறது?

A) Correlation
Correlation

✔️ **B) Variance**
Variance (பரவல் அளவு**)**

C) Mode
Mode

---

11. In a box plot, what represents the median of the data?

Box Plot-இல் **Median** எதை குறிக்கிறது**?**

A) Top whisker
மேல் whisker

B) Bottom whisker
கீழ் whisker

✔️ **C) Central line inside the box**
Box-இன் உள்ளே இருக்கும் நடு கோடு

---

12. When two variables move in opposite directions, what is the correlation called?

இரண்டு மாறிகளும் எதிர்மறை திசையில் நகர்ந்தால் அது என்ன **correlation?**

A) Positive correlation
Positive correlation

✔️ **B) Negative correlation**
Negative correlation

C) Neutral correlation
Neutral correlation

---

13. Which visualization is commonly used to show the frequency distribution of categorical data?

Categorical Data-வின் Frequency Distribution காட்ட எந்த chart பயன்படுத்தப்படுகிறது?

A) Line Chart
Line Chart

✔️ **B) Bar Plot**
Bar Plot

C) Violin Plot
Violin Plot

---

14. What is the primary purpose of using a heatmap in data visualization?

Data Visualization-இல் Heatmap பயன்படுத்துவதன் முக்கிய நோக்கம் என்ன?

A) To compare time-series data
Time-series data ஒப்பிடுவது

✔️ **B) To visualize the correlation between multiple variables**
பல மாறிகளுக்கிடையேயான **correlation-ஐ** காண்பிப்பது

C) To show the median value of a dataset
Dataset-இன் median value காட்டுவது

---

15. Which measure is often used to detect outliers in univariate analysis?

Univariate Analysis-இல் Outliers கண்டறிய எந்த measure பயன்படுத்தப்படுகிறது?

A) Mean
Mean

✔️ **B) Interquartile Range (IQR)**
Interquartile Range (IQR)

C) Correlation Coefficient
Correlation Coefficient

==========

1️⃣ Univariate Analysis – Goal

Q: What is the primary goal of Univariate Analysis?
Tamil: Univariate Analysis-இன் முக்கிய நோக்கம் என்ன?

✔ **Answer:** To summarize and describe the main characteristics of one variable
Tamil: ஒரு மாறியின் முக்கிய பண்புகளை விளக்குவது

Example:
ஒரு dataset-ல் **restaurant price** மட்டும் analyse செய்வது.

Price: 100, 200, 150, 120, 180

இதில்

- average price
- minimum
- maximum

பார்ப்பது **Univariate Analysis**.

2️⃣ Spread of a Single Variable

Q: Which visualization is best for identifying the spread of a single variable?

✔ **Answer:** Histogram

Example:
Student marks:

40, 50, 60, 70, 80, 90

Histogram காட்டும்

- எத்தனை students 40-50 range
- 50-60 range

இதனால் **data distribution** தெரியும்.

---

3 Bivariate Analysis

Q: In Bivariate Analysis, what is the main focus?

✔ **Answer:** Exploring the relationship between two variables

Example:

Study Hours	Marks
2	40
4	60
6	80

Study hours அதிகமானால் marks அதிகமாகிறது.
இது **relationship between two variables**.

---

4 Mean affected by Outliers

✔ **Answer:** Mean

Example

Marks:

40, 45, 50, 55, 100

Mean = 58

ஆனால் **100 outlier** mean-ஐ increase செய்தது.

Median = 50
Median stable.

---

5 Positive Skew

✔ **Answer:** Data has a longer tail on the right side

Example

Income data:

20k, 25k, 30k, 35k, 2 lakh

2 lakh காரணமாக **right side tail** நீளமாக இருக்கும்.

---

6 Relationship between Continuous Variables

✔ **Answer:** Scatter Plot

Example

Height	Weight
150	50
160	55
170	65

Scatter plot-ல்
points upward trend → relationship தெரியும்.

---

7 Normal Distribution

✔ **Answer:** Symmetrical bell-shaped curve

Example

Exam marks distribution

Few students → very low marks
Many students → average marks
Few students → very high marks

Graph shape = **Bell curve**

---

8 Correlation = 0.9

✔ **Answer:** Strong positive correlation

Example

Temperature	Ice Cream Sales
25°C	100
30°C	150
35°C	200

Temperature ↑
Sales ↑

Correlation ≈ **0.9**

---

9 Violin Plot

✔ **Answer:** Box Plot + KDE

Example

Violin plot காட்டும்:

- Median
- Quartiles

- Data density

அதனால் **box plot + distribution shape** இரண்டும் தெரியும்.

🔟 Variance

✔ **Answer:** Variance

Example

Dataset 1:

50, 51, 52

Dataset 2:

10, 50, 90

Dataset 2 → **more spread**
Variance அதிகம்.

1️⃣1️⃣ Median in Box Plot

✔ **Answer:** Central line inside the box

Example

Marks:

20, 30, 40, 50, 60

Median = **40**

Box plot-ல் நடுவில் line.

1⃣2⃣ Negative Correlation

✔ **Answer:** Negative correlation

Example

Price	Demand
10	100
20	80
30	50

Price ↑
Demand ↓

இதுதான் **Negative Correlation**.

1⃣3⃣ Categorical Frequency Chart

✔ **Answer:** Bar Plot

Example

Favourite fruit survey

Fruit	Count
Apple	20
Mango	30
Banana	15

Bar chart காட்டும் **frequency**.

1⃣4⃣ Heatmap Purpose

✔ **Answer:** To visualize correlation between multiple variables

Example

Correlation table

	Price	**Rating**	**Votes**
Price	1	0.3	0.5
Rating	0.3	1	0.7

Heatmap-ல் **colors** மூலம் correlation strength தெரியும்.

1⃣5⃣ Outlier Detection

✔ **Answer:** Interquartile Range (IQR)

Formula

IQR = Q3 − Q1

Outlier rule

Lower = Q1 − 1.5×IQR
Upper = Q3 + 1.5×IQR

Example

Data:

10, 12, 13, 14, 15, 100

100 → **outlier**

==========

Next set of MCQ

- **Tamil translation**
- **Correct answer**
- **Simple explanation**
- **Very simple real-life example** so it is easy to understand.

1️⃣ What is the primary purpose of Exploratory Data Analysis (EDA)?

Tamil:
Exploratory Data Analysis (EDA)-இன் முக்கிய நோக்கம் என்ன?

A) To find missing values
➡️ காணாமல் போன மதிப்புகளை கண்டறிதல்

B) To summarize data and find patterns
➡️ தரவை சுருக்கமாக புரிந்து கொண்டு அதில் உள்ள மாதிரிகளை கண்டறிதல்

C) To create machine learning models
➡️ மெஷின் லெர்னிங் மாதிரிகளை உருவாக்குதல்

✅ **Answer: B) To summarize data and find patterns**

Explanation:
EDA என்பது தரவை முதலில் ஆய்வு செய்து **trend, pattern, relationship, outliers** போன்றவற்றை கண்டறிவது.

Simple Example:
ஒரு restaurant dataset இருந்தால்:

- எந்த area-வில் அதிக restaurants?
- எந்த cuisine அதிக rating?

EDA மூலம் இதை கண்டுபிடிக்கலாம்.

2️⃣ Which of the following is not a Data Science sub-domain?

Tamil:
கீழ்கண்டவற்றில் எது **Data Science-**இன் துணைப் பிரிவு அல்ல**?**

A) Descriptive Analysis
➡️ விவரிக்கும் பகுப்பாய்வு

B) Reinforcement Learning
➡️ Reinforcement Learning

C) Time Series Forecasting
➡️ காலவரிசை கணிப்பு

✅ **Answer: B) Reinforcement Learning**

Explanation:
Data Science subdomains:

- Descriptive Analytics
- Predictive Analytics
- Prescriptive Analytics

Reinforcement Learning என்பது **Machine Learning technique**.

Simple Example:

Type	Example
Descriptive	Last year sales analysis
Predictive	Next month sales prediction
Prescriptive	Which product to promote

3️⃣ Which process helps in detecting patterns and anomalies in data before modeling?

Tamil:
Model உருவாக்குவதற்கு முன் தரவில் **pattern** மற்றும் **anomaly** கண்டறிய எந்த **process** உதவும்?

A) Data Visualization
➡️ தரவு காட்சிப்படுத்தல்

B) Model Evaluation
➡️ மாதிரி மதிப்பீடு

C) Model Training
➡️ மாதிரி பயிற்சி

✅ **Answer: A) Data Visualization**

Explanation:
Charts மூலம் data pattern எளிதாக தெரியும்.

Simple Example:

Sales graph:

Month	Sales
Jan	100
Feb	110
Mar	105
Apr	500

April value **outlier** என்பதை graph மூலம் பார்க்கலாம்.

4️⃣ What is the main characteristic of structured data?

Tamil:
Structured Data-வின் முக்கிய பண்பு என்ன**?**

A) It has no format
➡️ வடிவமைப்பு இல்லை

B) It is organized into rows and columns
➡️ வரிசைகள் மற்றும் நெடுவரிசைகள்

C) It includes images and videos
➡️ படங்கள் மற்றும் வீடியோக்கள்

✅ **Answer: B) It is organized into rows and columns**

Explanation:
Structured data என்பது **table format**.

Simple Example:

Name	Age	City
Ravi	25	Chennai
Kumar	30	Madurai

5️⃣ In supervised learning, what do you predict?

Tamil:
Supervised Learning-ல் நாம் எதை **predict** செய்கிறோம்**?**

A) Clusters
➡️ குழுக்கள்

B) Labels or outcomes
➡️ முடிவுகள் அல்லது லேபிள்கள்

C) Missing values
➡️ காணாமல் போன மதிப்புகள்

✅ **Answer: B) Labels or outcomes**

Explanation:
Supervised learning-ல் **input + known output** இருக்கும்.

Simple Example:

Hours Study	Pass/Fail
2	Fail
5	Pass

Model prediction → **Pass or Fail**

6️⃣ What is the best central tendency for skewed data?

Tamil:
Skewed data-க்கு எந்த central tendency சிறந்தது?

A) Mean

B) Median

C) Mode

✅ **Answer: B) Median**

Explanation:
Outliers mean-ஐ பாதிக்கும்.

Median பாதிக்காது.

Simple Example:

Salary:

10k, 12k, 11k, 13k, **1,00,000**

Mean = misleading
Median = realistic value

7️⃣ Which statistical method measures the relationship between two variables?

Tamil:
இரண்டு மாறிகளுக்கிடையிலான உறவை அளவிட எந்த **method?**

A) Correlation

B) Regression

C) Variance

✅ **Answer: A) Correlation**

Explanation:
Correlation value:

- +1 → strong positive
- 0 → no relation
- -1 → strong negative

Simple Example:

Temperature ↑
Ice cream sales ↑

Positive correlation.

8️⃣ What is the purpose of confidence interval?

Tamil:
Confidence interval-ன் முக்கிய நோக்கம் என்ன?

A) Future prediction

B) Population parameter range estimate

C) Variance calculation

✅ **Answer: B) To estimate range**

Explanation:
Confidence interval population value எந்த range-ல் இருக்கலாம் என்பதை காட்டும்.

Simple Example:

Survey result:

Average height = 170 cm

95% CI → **168 – 172 cm**

9️⃣ Which correlation value shows perfect negative relationship?

Tamil:
Perfect negative relationship value எது?

A) 0

B) -1

C) 1

✅ **Answer: B) -1**

Explanation:

Example:

Price ↑
Demand ↓

Perfect negative correlation.

🔟 When is Chi-Square test used?

Tamil:
Chi-Square test எப்போது பயன்படுத்தப்படுகிறது**?**

A) Means compare

B) Categorical variables independence

C) Variance measure

✅ **Answer: B) Categorical independence**

Explanation:
Two categorical variables relationship.

Simple Example:

Gender	Product
Male	Phone
Female	Laptop

Gender product choice-ஐ influence செய்கிறதா என பார்க்க.

1️⃣1️⃣ Which plot shows distribution of a single variable?

Tamil:
ஒரு **variable distribution** பார்க்க எந்த **plot?**

A) Line Plot

B) Box Plot

C) Bar Plot

✅ **Answer: B) Box Plot**

Explanation:
Box plot shows:

- median
- quartiles
- outliers

Simple Example:

Students marks distribution.

1️⃣2️⃣ What does scatter plot show?

Tamil:
Scatter plot என்ன காட்டுகிறது?

A) Relationship between two variables

B) Frequency distribution

C) Average

✅ **Answer: A) Relationship**

Explanation:
Scatter plot → variable relationship.

Simple Example:

Study Hours	Marks
2	40

4	60
6	80

Hours ↑ → Marks ↑

1️⃣3️⃣ Which visualization suits categorical data?

Tamil:
Categorical data-க்கு எந்த visualization சிறந்தது?

A) Line chart

B) Pie chart

C) Histogram

✅ **Answer: B) Pie Chart**

Explanation:
Pie chart category percentage காட்டும்.

Simple Example:

Market share:

Brand	%
Apple	40
Samsung	35
Others	25

1⃣4⃣ What do whiskers represent in box plot?

Tamil:
Box plot-ல் whiskers என்னைக் குறிக்கின்றன?

A) Mean

B) Median

C) Range of non-outlier data

✅ **Answer: C) Range of non-outlier data**

Explanation:
Whiskers show **minimum and maximum values** excluding outliers.

Simple Example:

Marks:

20, 25, 30, 35, 90

90 → outlier
Whiskers → 20 to 35.

1⃣5⃣ Which visualization helps identify outliers?

Tamil:
Outliers கண்டறிய எந்த visualization?

A) Histogram

B) Box Plot

C) Line Plot

✅ **Answer: B) Box Plot**

Explanation:
Box plot outliers-ஐ clearly dots ஆக காட்டும்.

Simple Example:

Salary data:

20k, 22k, 21k, 23k, **5,00,000**

5,00,000 → Outlier.

==========

Data Set_Debuggingwithanswers & Explanations

Below I show **each code in 3 parts**:

1️⃣ **Error Version (Original Code)**
2️⃣ **Correct Version**
3️⃣ **Explanation – What was wrong and what was corrected**

1️⃣ Error in Mean Calculation (Mixed Data Types)

❌ Error Version

```
import pandas as pd

data = {'Name': ['Alice', 'Bob', 'Charlie'],
        'Age': [25, 30, 'Thirty-Five'],
        'Gender': ['F', 'M', 'M']}

df = pd.DataFrame(data)

average_age = df['Age'].mean()

print(f"Average Age: {average_age}")
```

✅ Correct Version

```
import pandas as pd

data = {'Name': ['Alice', 'Bob', 'Charlie'],
        'Age': [25, 30, 35],
        'Gender': ['F', 'M', 'M']}

df = pd.DataFrame(data)

average_age = df['Age'].mean()

print(f"Average Age: {average_age}")
```

🔎 Explanation

Problem:
`Age` column contains **string "Thirty-Five"**.

Mean calculation requires **numeric values**.

Fix:
Convert to numeric value **35**.

2️⃣ Error in Percentile Calculation

❌ Error Version

```
import numpy as np

data = [1,2,3,4,5,6,7,8,9,10]

q1, q3 = np.percentile(data, 25, 75)
```

✅ Correct Version

```
import numpy as np

data = [1,2,3,4,5,6,7,8,9,10]

q1, q3 = np.percentile(data, [25, 75])

print(q1, q3)
```

🔎 Explanation

Problem:
`np.percentile()` expects **list of percentiles**.

Wrong:

np.percentile(data, 25, 75)

Correct:

np.percentile(data, [25, 75])

3️⃣ Error in Outlier Detection Using Z-score

❌ Error Version

```
import numpy as np
from scipy.stats import zscore

data = [1,2,3,100,5,6,7,8,9]

outliers = [i for i in data if zscore(data) > 2]
```

✅ Correct Version

```
import numpy as np
from scipy.stats import zscore

data = [1,2,3,100,5,6,7,8,9]

z_scores = zscore(data)

outliers = [data[i] for i in range(len(data)) if abs(z_scores[i]) > 2]

print(outliers)
```

🔎 Explanation

Problem:

`zscore(data)` returns **array**, not single value.

Comparison must be done **element-wise**.

Fix:

Compute z-scores first, then check each value.

4️⃣ Error in Outlier Replacement

❌ Error Version

```
data = [median if abs(zscore(x)) > 2 else x for x in data]
```

✅ Correct Version

```
import numpy as np
from scipy.stats import zscore

data = [1,2,3,100,5,6,7,8,9]

z_scores = zscore(data)
median = np.median(data)

data = [median if abs(z_scores[i]) > 2 else data[i] for i in range(len(data))]

print(data)
```

🔎 Explanation

Problem:

`zscore(x)` cannot be applied to **single number**.

It must be applied to **entire dataset**.

Fix:

Calculate z-score list first.

5️⃣ Error in Normal Distribution PDF

❌ Error Version

```
from scipy.stats import norm

pdf_val = norm.pdf(2, 0, -1)
```

✅ Correct Version

```
from scipy.stats import norm

pdf_val = norm.pdf(2, 0, 1)

print(pdf_val)
```

🔎 Explanation

Problem:

Standard deviation **cannot be negative**.

Wrong:

-1

Correct:

1

6️⃣ Error in Seaborn Pairplot

❌ Error Version

```
import seaborn as sns
import pandas as pd

df = pd.DataFrame({'A':[1,2,3],'B':[4,5,6]})
sns.pairplot(df, hue='C')
```

✅ Correct Version

```
import seaborn as sns
import pandas as pd

df = pd.DataFrame({
  'A':[1,2,3],
```

```
  'B':[4,5,6],
  'C':['X','Y','X']
})

sns.pairplot(df, hue='C')
```

🔎 Explanation

Problem:

Column **C does not exist**.

Fix:

Add column `C` to dataframe.

7️⃣ Error in Covariance Matrix

❌ Error Version

```
import numpy as np

x = [1,2,3,4]
y = [2,4,6,8]

cov_matrix = np.cov()
```

✅ Correct Version

```
import numpy as np

x = [1,2,3,4]
y = [2,4,6,8]

cov_matrix = np.cov(x, y)

print(cov_matrix)
```

🔎 Explanation

Problem:

`np.cov()` requires **input variables**.

Fix:

Pass `x` and `y`.

8️⃣ Error in Mean Calculation (Missing Function)

❌ Error Version

```
import numpy as np

data = [2,4,6,8,10]

mean_value = mean(data)
print(mean_value)
```

✅ Correct Version

```
import numpy as np

data = [2,4,6,8,10]

mean_value = np.mean(data)

print(mean_value)
```

🔎 Explanation

Problem:

`mean()` function is not defined.

Fix:

Use:

np.mean()

9️⃣ Error in Replace NaN

❌ Error Version

```
df.replace(np.nan, 0, inplace=False)
print(df)
```

✅ Correct Version

```
df = df.replace(np.nan, 0)

print(df)
```

🔎 Explanation

Problem:

`inplace=False` returns new dataframe but not saved.

Fix:

Assign back to `df`.

🔟 Error in Correlation Calculation

❌ Error Version

```
correlation = np.corrcoef()
print(correlation)
```

✅ Correct Version

```
correlation = np.corrcoef(df['A'], df['B'])

print("Correlation:\n", correlation)
```

🔎 Explanation

Problem:

`np.corrcoef()` requires **input arrays**.

Fix:

Provide columns A and B.

==========